


Hướng dẫn xây dựng dataset dự báo hạn hán ĐBSCL

Tài liệu này hướng dẫn từng bước: tải dữ liệu đủ 5 trạm → kiểm tra chất lượng → dựng dataset (SPEI, đặc trưng, nhãn) để dùng cho mô hình dự báo.


0. Tổng quan quy trình



Bước	Script	Việc làm	Đầu ra
1	src/fetch_api.py	Tải dữ liệu ngày và giờ từ Open-Meteo cho 5 trạm	data/interim/<ID>_daily.csv
2	src/validate_raw.py	Kiểm tra thiếu ngày, NaN, ngoài ngưỡng, giá trị đứng yên	reports/validation_report.csv
3	src/build_dataset.py	Gộp tháng, tính SPEI, tạo đặc trưng và nhãn	data/processed/*.csv

1. Chuẩn bị

1.1. Cấu trúc thư mục



Tạo các thư mục còn thiếu:

Lưu ý: tên thư mục hiện tại của bạn là `mekong_drought_t_forecast` (có khoảng trắng). Nên đổi thành `mekong_droughtt_forecast` để tránh lỗi đường dẫn. Sau khi đổi tên cần tạo lại môi trường ảo `.venv` (hoặc sửa lại đường dẫn `source`).

```
cd /đường/dẫn/tới/mekong_drought_forecast
source .venv/bin/activate
pip install pandas numpy scipy pyyaml requests
```

```
python -c "import pandas, numpy, scipy, yaml; print('OK')"
```

- Chép `config.yaml` mới đè lên file cũ (ở thư mục gốc dự án).
- Chép `validate_raw.py` và `build_dataset.py` vào thư mục `src/`.

Các điểm quan trọng:

2 / 8

Tham số	Giá trị	Ý nghĩa
<code>stations</code>	5 trạm	Bến Tre, Cà Mau, Rạch Giá, Cao Lãnh, Long Xuyên

Quy tắc YAML cần nhớ:

- Dòng con thụt lề đúng 2 dấu cách dưới dòng cha.
- Không viết chữ thừa sau giá trị. Bình luận phải bắt đầu bằng `#`, ví dụ `raw: data/raw # nơi lưu dữ liệu thô`.

Kiểm tra config trước khi chạy:

```
python -c "import yaml; c=yaml.safe_load(open('config.yaml'));  
print(c['period']); print(c['paths']); print(len(c['stations']), 'tram')"
```

Kết quả đúng: `calib_start: 1991, end: 2025`, và 5 trạm.

3. Bước 1: Crawl đủ dữ liệu

```
python src/fetch_api.py 2>&1 | tee logs/fetch_full.log
```

Lệnh `tee` vừa in ra màn hình vừa lưu log để bạn xem lại.

Thời gian chạy thường vài phút đến vài chục phút vì có `sleep_seconds` giữa các lần gọi API.

Kết quả mong đợi cho mỗi trạm:

- `data/interim/<ID>_daily.csv` gồm khoảng 12.784 dòng dữ liệu + 1 dòng tiêu đề (1991-01-01 → 2025-12-31 là 35 năm, có 9 năm nhuận).
- Các file thô theo giờ của độ ẩm đất nằm trong `data/raw/`, giữ lại để tái lập kết quả.

Kiểm tra nhanh:

```
ls data/interim  
wc -l data/interim/*_daily.csv  
head -3 data/interim/BT_daily.csv
```

Cột của file ngày:

```
date, precipitation_sum, temperature_2m_max, et0_fao_evapotranspiration,  
soil_moisture_0_to_7cm_mean
```

Xử lý sự cố khi crawl

Hiện tượng	Nguyên nhân	Cách xử lý
400 Bad Request	Sai ngày (ví dụ năm gõ nhầm 1023) hoặc sai tên biến	Kiểm tra period và daily_vars trong config
429 Too Many Requests	Vượt giới hạn lượt gọi của API miễn phí	Đợi khoảng 1 giờ, tăng sleep_seconds lên 3, chạy lại
Lỗi mạng giữa chừng	Mất kết nối	Chạy lại. Nếu script không bỏ qua trạm đã tải, xóa file của trạm lỗi rồi chạy lại
Lỗi YAML	Sai thụt lề hoặc chữ thừa	Chạy lệnh kiểm tra config ở mục 2

Ghi chú: API miễn phí của Open-Meteo chỉ dành cho mục đích phi thương mại, phù hợp đồ án học thuật.

4. Bước 2: Kiểm tra tính hợp lệ của dữ liệu

```
python src/validate_raw.py
```

4.1. Script kiểm tra những gì

Kiểm tra	Mức độ	Ý nghĩa
Thiếu file hoặc thiếu cột	ERROR	Bước crawl chưa hoàn tất
Ngày bị trùng	ERROR	Cần loại bỏ dòng trùng
Thiếu ngày so với 1991-01-01 → 2025-12-31	ERROR	Chuỗi thời gian không liên tục, sẽ làm sai tổng trượt và SPEI
NaN ở mưa, Tmax, ET0	ERROR	Không được thiếu
NaN ở độ ẩm đất sau 2010	ERROR	Phải đủ từ 2010
Giá trị ngoài ngưỡng	ERROR	Mưa 0–400 mm, Tmax 15–42 °C, ET0 0–10 mm/ngày, độ ẩm đất 0,02–0,60
Số dòng giữa các trạm khác nhau	ERROR	Có trạm tải thiếu
Mưa > 150 mm/ngày	WARN	Có thể là mưa cực đoan thật, cần xem xét
Chuỗi từ 5 ngày liên cùng một giá trị Tmax hoặc ET0	WARN	Có thể do lỗi dữ liệu
Tổng mưa năm ngoài 500–4000 mm	WARN	Cần xem lại năm đó
Độ ẩm đất chạm trần (≥ 20% số ngày)	INFO	Bảo hòa của mô hình, không phải số đo thực

Độ ẩm đất NaN trước 2010 là chủ định, không bị tính là lỗi.

4.2. Đọc kết quả

Ví dụ dòng in ra:

```
[ERROR] CM missing_dates thiếu 31 ngày, ví dụ ['2005-03-01', ...]
[WARN ] KG heavy_rain      3 ngày mưa > 150 mm (kiểm tra có thật không)
[INFO ] BT rows            12784 dòng, 1991-01-01 → 2025-12-31
```

- **ERROR:** bắt buộc sửa rồi chạy lại. Cách thường dùng là tải lại trạm đó.
- **WARN:** xem xét và ghi chú vào báo cáo, không nhất thiết phải sửa.
- **INFO:** thông tin để mô tả dữ liệu.

Script thoát với mã 1 nếu còn ERROR. Chỉ sang bước 3 khi hết ERROR.

Báo cáo chi tiết nằm ở [reports/validation_report.csv](#), có thể đưa vào phụ lục của đồ án.

5. Bước 3: Dựng dataset

```
python src/build_dataset.py
```

5.1. Các bước xử lý bên trong

a) Gộp từ ngày sang tháng

Cột	Cách tính
<code>precip_sum</code>	Tổng mưa tháng
<code>et0_sum</code>	Tổng ET0 tháng
<code>tmax_mean, tmax_max</code>	Trung bình và cực đại của Tmax
<code>rain_days</code>	Số ngày mưa ≥ 1 mm
<code>soil_mean</code>	Trung bình độ ẩm đất

Tháng nào chưa đủ ngày (ví dụ tháng cuối) bị loại để tránh thiên lệch.

b) Cân bằng nước

$$D = P - ET_0 \quad (\text{mm/tháng})$$

D âm kéo dài nghĩa là thiếu nước, tức hạn.

c) SPEI-1, SPEI-3, SPEI-6

1. Tổng trượt D trên 1, 3, 6 tháng.

- Với mỗi tháng trong năm (1–12), fit phân phối log-logistic 3 tham số (phương pháp PWM của Vicente-Serrano) trên giai đoạn chuẩn 1991–2020.
- Chuyển xác suất tích lũy sang phân phối chuẩn chuẩn hóa. Kết quả có trung bình ≈ 0 và độ lệch chuẩn ≈ 1 .

Phân loại hạn tham khảo:

SPEI	Mức
$\leq -2,0$	Hạn cực đoan
$-2,0$ đến $-1,5$	Hạn nặng
$-1,5$ đến $-1,0$	Hạn vừa
$-1,0$ đến $1,0$	Bình thường
$\geq 1,0$	Ẩm ướt

d) Đặc trưng

- Mùa vụ: `month_sin`, `month_cos`.
- ENSO: `oni_lag2`, `oni_lag3`. ONI là trung bình trượt 3 tháng nên phải trễ từ 2 tháng để không rò rỉ dữ liệu. Script tự tải file ONI từ NOAA vào `data/external/oni.ascii.txt`.
- Độ trễ 1, 2, 3 tháng (`_lag1`, `_lag2`, `_lag3`) của: `precip_sum`, `et0_sum`, `D`, `tmax_mean`, `soil_mean`, `spei1`, `spei3`, `spei6`.

e) Nhãn dự báo

Cột	Ý nghĩa
<code>target_spei3_h1/h2/h3</code>	SPEI-3 của 1, 2, 3 tháng sau (bài toán hồi quy)
<code>target_drought_h1/h2/h3</code>	1 nếu SPEI-3 tháng đó ≤ -1 , ngược lại 0 (bài toán phân loại)

f) Chia tập theo thời gian

Tập	Giai đoạn
train	≤ 2018
val	2019–2021
test	≥ 2022

Không xáo trộn ngẫu nhiên vì dữ liệu chuỗi thời gian.

5.2. Hai file đầu ra

File	Nội dung	Dùng khi
<code>dataset_monthly_full.csv</code>	Từ 1991, độ ẩm đất NaN trước 2010	Phân tích EDA, vẽ lịch sử SPEI 1991–2025

File	Nội dung	Dùng khi
<code>dataset_monthly_ml.csv</code>	Từ 2010, đã bỏ dòng thiếu đặc trưng do lag	Huấn luyện mô hình

5.3. Kiểm tra SPEI có đúng không

Cuối lần chạy, script in bảng sanity check trên giai đoạn chuẩn. SPEI đúng khi:

- `mean` xấp xỉ 0.
- `std` xấp xỉ 1.
- `frac_dry` (tỷ lệ tháng có $\text{SPEI}-3 \leq -1$) khoảng 0,16.

Nếu lệch nhiều (ví dụ `frac_dry` quá thấp hoặc quá cao), kiểm tra lại dữ liệu tháng hoặc báo lỗi để xem lại bước fit.

6. Danh sách kiểm tra cuối (checklist)

- ☐ `config.yaml` đã có `calib_start: 1991, end: 2025`, đủ 5 trạm.
- ☐ Có đủ 5 file `data/interim/*_daily.csv`, số dòng bằng nhau.
- ☐ `validate_raw.py` không còn ERROR.
- ☐ Có `data/external/oni.ascii.txt` (nếu không, cột ONI sẽ là NaN).
- ☐ Bảng sanity check SPEI: $\text{mean} \approx 0$, $\text{std} \approx 1$, tỷ lệ hạn $\approx 0,16$.
- ☐ Có `data/processed/dataset_monthly_ml.csv`.
- ☐ Lưu lại `logs/fetch_full.log` và `reports/validation_report.csv` làm bằng chứng cho báo cáo.

7. Lưu ý khi viết báo cáo đồ án

1. **Nguồn dữ liệu:** đây là dữ liệu tái phân tích theo ô lưới (ERA5 / ERA5-Land qua Open-Meteo), không phải số đo tại trạm. Nêu rõ điều này, kèm độ lệch tọa độ ô lưới so với trạm (ví dụ Bến Tre lệch khoảng 3 km).
2. **Độ ẩm đất chạm trần 0,43:** đây là ngưỡng bão hòa của mô hình, không phải giá trị đo thật. Các đợt mưa lớn không còn phân biệt được qua cột này.
3. **Chống rò rỉ dữ liệu:** đặc trưng tháng `t` chỉ dùng dữ liệu đến hết tháng `t`, nhấn là tương lai, ONI trễ từ 2 tháng, SPEI fit trên giai đoạn chuẩn cố định.
4. **Khoảng đệm giữa các tập:** vì nhấn nhìn trước tối đa 3 tháng, 3 tháng cuối của train có thể chồng nhẹ sang val. Hãy bỏ một khoảng đệm 3 tháng hoặc ghi chú rõ.
5. **Lớp hạn ít hơn lớp không hạn:** dùng `class_weight` hoặc thước đo F1 / PR-AUC thay vì chỉ dùng accuracy.
6. **Baseline để so sánh:** persistence (dự báo SPEI tương lai bằng SPEI hiện tại), sau đó mới đến Random Forest, XGBoost.
7. **Khả năng tái lập:** giữ nguyên `config.yaml`, các file thô trong `data/raw/` và phiên bản thư viện (`pip freeze > requirements.txt`).

8. Bước tiếp theo gợi ý

1. **EDA**: biểu đồ mưa, ET0, độ ẩm đất theo mùa; chuỗi SPEI-3 theo năm; so sánh vùng ven biển và nội địa.
2. **Mô hình baseline**: persistence, hồi quy tuyến tính, Random Forest cho `target_spei3_h1..h3`.
3. **Đánh giá**: RMSE, MAE, R^2 cho hồi quy; F1, PR-AUC cho phân loại hạn; báo cáo theo từng trạm và từng horizon.